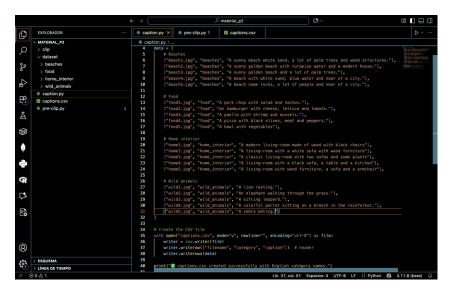
Parte 1: dataset

Las 4 categorías que elegí fueron: "beaches", "wild_animals", "food" y "home interior" y añadía 5 imágenes a cada una.



Luego realicé este script en python para generar un csv con una pequeña descripción de cada imagen.

```
beach1.jpg,beaches,"A sunny beach white sand, a lot of palm trees and wood structures."
beach2.jpg,beaches,A sunny golden beach with turqoise water and a modern house.
beach3.jpg,beaches,A sunny golden beach and a lot of palm trees.
beach4.jpg,beaches,"A beach with white sand, blue water and near of a city."
beach5.jpg,beaches,"A beach some rocks, a lot of people and near of a city."
food1.jpg,food,A pork chop with salad and nachos.
food2.jpg,food,"An hamburger with cheese, lettuce and tomate."
food3.jpg,food,A paella with shrimp and mussels.
food4.jpg,food,"A pizza with black olive
                                         Col 3: caption
food5.jpg,food,A bawl with vegetables
home1.jpg,home_interior,A modern living-room made of wood with black chairs
home2.jpg,home_interior,A living-room with a white sofa with wood furniture
home3.jpg,home_interior,A classic living-room with two sofas and some plants
home4.jpg,home_interior,"A living-room with a black sofa, a table and a kitchen"
home5.jpg,home_interior,"A living-room with wood furniture, a sofa and a armchair"
wild1.jpg,wild_animals,A lion resting.
wild2.jpg,wild_animals,An elephant walking through the grass.
wild3.jpg,wild_animals,A sitting leopard.
wild4.jpg,wild_animals,A colorful parrot sitting on a branch in the rainforest.
wild5.jpg,wild_animals,A zebra eating.
```

Parte2: Pre-CLIP

1. Normalicé y transformé las imágenes para el formato que usa ResNet50.

```
# ------
# MODELO DE IMAGEN: ResNet50 preentrenada
# ------
resnet = resnet50(pretrained=True)
resnet = torch.nn.Sequential(*(list(resnet.children())[:-1]))
resnet.eval()
resnet.to(device)
```

2. Utilicé el modelo ya preentrenado de pytorch de ResNet50 pero quitando la última capa para obtener embeddings puros

```
# ------
# MODELO DE TEXTO: SentenceTransformer
# ------
text_model = SentenceTransformer('distiluse-base-multilingual-cased-v1', device=device)
```

3. Utilicé el modelo de texto 'distiluse-base-multilingual-cased-v1'

4. Normalicé embeddings de imágenes y textos.

5. Proyecté los embeddings de imagen a la dimensión de texto (512) para poder comparar con cosine similarity.

6. Calculé la Top-1 accuracy, es decir, cuántas imágenes matchean con su caption correcto.

7. Imprime la matriz de similitud, útil para ver qué imágenes están más cercanas a qué captions.

filename	beach1.jpg	beach2.jpg	beach3.jpg	beach4.jpg	 wild2.jpg	wild3.jpg	wild4.jpg	wild5.jpg
filename								
beach1.jpg	-0.027	-0.000	-0.003	-0.004	 0.005	0.000	-0.000	-0.049
beach2.jpg	-0.010	-0.000	0.013	-0.042	 0.018	0.036	0.020	-0.048
beach3.jpg	0.005	-0.000	0.017	-0.032	 0.018	0.023	-0.002	-0.035
beach4.jpg	-0.019	-0.020	-0.012	0.005	 -0.014	0.003	0.002	-0.036
beach5.jpg	-0.032	-0.027	-0.020	-0.019	 -0.012	-0.002	0.005	-0.049
food1.jpg	-0.025	-0.037	0.009	-0.016	 -0.008	0.077	0.030	-0.047
food2.jpg	-0.057	-0.060	-0.045	-0.060	 -0.039	0.023	0.005	-0.033
food3.jpg	-0.011	-0.049	-0.010	-0.012	 -0.005	0.044	0.012	-0.066
food4.jpg	-0.009	-0.042	-0.006	-0.016	 -0.018	0.027	0.024	-0.047
food5.jpg	-0.034	-0.031	-0.025	-0.008	 -0.032	0.021	0.018	-0.070
home1.jpg	-0.059	-0.059	-0.062	-0.014	 -0.061	-0.061	-0.046	-0.104
home2.jpg	-0.074	-0.015	-0.071	-0.019	 -0.032	-0.022	-0.062	-0.080
home3.jpg	-0.055	-0.021	-0.069	0.003	 -0.033	-0.027	-0.038	-0.088
home4.jpg	-0.029	-0.009	-0.041	0.016	 -0.031	-0.013	-0.054	-0.096
home5.jpg	-0.033	-0.014	-0.036	0.008	 -0.053	-0.013	-0.038	-0.098
wild1.jpg	-0.005	-0.023	-0.018	-0.007	 -0.053	-0.019	-0.004	-0.089
wild2.jpg	-0.038	-0.029	-0.010	-0.012	 -0.005	0.002	0.022	-0.053
wild3.jpg	-0.022	0.001	-0.004	-0.031	 -0.026	0.019	-0.019	-0.088
wild4.jpg	-0.018	-0.000	-0.018	-0.030	 -0.022	0.015	0.014	-0.073
wild5.jpg	-0.017	-0.019	-0.035	-0.036	 -0.038	-0.009	0.005	-0.065

Esta sería la matriz de las distancias coseno. Los valores oscilan entre negativos y positivos muy bajos (-0.1 ... 0.1). No hay un patrón claro de "imagen coincide con su caption": los máximos no están en la diagonal. Esto refuerza que los embeddings de imagen y texto no están directamente comparables, a menos que hagas un proyecto de alineación (como lo hace CLIP).

La Top-1 accuracy me da 5.00%. Esto significa que solo 1 de cada 20 imágenes coincide correctamente con su caption según la similitud coseno. Cómo el valor es tan bajo, la red de imagen y la de texto no están alineadas, porque cada una genera embeddings en espacios distintos.

El resultado demuestra la limitación que hay al utilizar modelos separados para imágenes y texto.

Parte 3: Clip

1. Cargué cada imagen y su caption al igual que en el preclip

```
# ------
# CARGAR MODELO CLIP
# ------
model_name = "openai/clip-vit-base-patch32"
model = CLIPModel.from_pretrained(model_name).to(device)
processor = CLIPProcessor.from_pretrained(model_name)
```

Usé CLIPProcessor para procesar imagen y texto simultáneamente.

```
# EMBEDDINGS DE IMÁGENES Y TEXTOS
image_embeddings = []
text_embeddings = []
for idx, row in df.iterrows():
    # Imagen
    category = row['category']
    filename = row['filename']
    img_path = os.path.join(dataset_dir, category, filename)
    image = Image.open(img_path).convert("RGB")
    # Procesar imagen y caption
    inputs = processor(text=row['caption'], \ images=image, \ return\_tensors="pt", \ padding=True).to(device)
    with torch.no_grad():
        outputs = model(**inputs)
        # image_embedding: [1, 512], text_embedding: [1, 512]
        image_emb = F.normalize(outputs.image_embeds, p=2, dim=1)
        text_emb = F.normalize(outputs.text_embeds, p=2, dim=1)
    image_embeddings.append(image_emb)
    text_embeddings.append(text_emb)
image_embeddings = torch.cat(image_embeddings, dim=0) # (num_images, 512)
text_embeddings = torch.cat(text_embeddings, dim=0) # (num_images, 512)
```

2. Obtuve los embeddings **normalizados** de imagen y texto. A diferencia del pre-clip, ya obtuve ambos en el mismo bucle al utilizar el mismo modelo para ambos.

```
# -----
# SIMILITUD COSENO
# -----
similarities = image_embeddings @ text_embeddings.T # (num_images, num_texts)
```

3. Calculé similaridad coseno entre cada imagen y todas las captions.

4. Calculé un **Top-1 accuracy**, que indica cuántas imágenes coinciden con su caption correcto.

```
# ------
# MATRIZ DE SIMILITUD
# ------
import pandas as pd
sim_matrix = similarities.cpu().numpy()
sim_df = pd.DataFrame(sim_matrix, index=df['filename'], columns=df['filename'])
print("\nCosine similarity matrix (images x captions) with CLIP:")
print(sim_df.round(3))
```

5. Para imprimir la matriz de similitud.

```
Cosine similarity matrix (images x captions) with CLIP: filename beach1.jpg beach2.jpg beach3.jpg beach4.jpg ... wild2.jpg wild3.jpg wild4.jpg wild5.jpg filename beach1.jpg 0.276 0.249 0.283 0.289 ... 0.141 0.133 0.109 0.156 beach2.jpg 0.240 0.257 0.259 0.282 ... 0.154 0.159 0.121 0.143 beach3.jpg 0.271 0.258 0.299 0.277 0.163 0.154 0.159 0.121 0.143 beach4.jpg 0.224 0.264 0.233 0.312 ... 0.131 0.125 0.079 0.136 beach5.jpg 0.230 0.249 0.232 0.297 0.125 0.133 0.125 0.079 0.136 beach5.jpg 0.230 0.249 0.325 0.297 0.125 0.133 0.642 0.132 food1.jpg 0.092 0.158 0.125 0.089 0.123 0.123 0.150 0.079 0.224 food2.jpg 0.092 0.158 0.128 0.106 0.122 0.113 0.089 0.192 food3.jpg 0.100 0.177 0.136 0.135 0.073 0.118 0.106 0.131 food4.jpg 0.108 0.135 0.127 0.115 0.135 0.073 0.118 0.106 0.131 food4.jpg 0.108 0.131 0.105 0.165 0.127 0.115 0.111 0.149 0.111 0.204 food5.jpg 0.108 0.131 0.105 0.165 0.165 0.127 0.150 0.093 0.193 bome2.jpg 0.135 0.224 0.148 0.138 0.121 0.152 0.084 0.158 bome2.jpg 0.135 0.224 0.148 0.138 0.121 0.152 0.084 0.158 bome2.jpg 0.155 0.224 0.148 0.139 0.159 0.123 0.168 0.111 0.152 bome4.jpg 0.155 0.227 0.162 0.169 0.159 0.123 0.168 0.111 0.152 bome4.jpg 0.155 0.227 0.162 0.169 0.160 0.123 0.168 0.111 0.152 bome4.jpg 0.155 0.227 0.162 0.162 0.162 0.122 0.156 0.079 0.165 0.075 0.165 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175 0.175
```

La diagonal tiene valores más altos (≈0.25–0.34) que el resto de la matriz. Esto indica que cada imagen está más cerca de su caption correcto que de otros captions. Las similitudes fuera de la diagonal son menores, aunque algunas categorías similares (ej. playas entre sí) pueden tener valores moderadamente altos, lo cual es normal.

Top-1 accuracy (image matches its caption with CLIP): 65.00%

Tiene bastante más que el pre-clip, esto es debido a que alinea embeddings de imagen y texto en el mismo espacio.